

# Redes Complexas

## Uma introdução

Leandro Chaves Rêgo, Jesus Ossian Cunha, Pablo Ignacio Fierens

Universidade Federal do Ceará

05 e 06 de Novembro de 2024

# Conteúdo

## 1 Métricas de Centralidade

## Métricas de Centralidade

# Conceito de centralidade

## Quem são os principais vértices da rede?

- Qual o aeroporto mais importante em uma rede representando a malha aérea de aviões?
- Como identificar os perfis mais importantes em uma rede social para apresentar um determinado anúncio?

## Métricas de centralidade

Fazem parte de um grupo de métricas de redes chamadas métricas locais, que descrevem características individuais dos nós.

# Métricas Geométricas

## Conceito

- Associa a centralidade ou importância de um nó com respeito a distância geodésica deste nó em relação aos demais nós da rede.
- Em grafos direcionados, existem duas opções: diferem se consideramos as distâncias a partir do nó ou distâncias para chegar no nó que estamos calculando a centralidade.
- Para simplificar, iremos descrever de acordo com a primeira opção.

# Métricas geométricas

## Excentricidade

Seja  $G_i = (V_i, E_i)$  a componente da rede que contém o nó  $i$ . A excentricidade do nó  $i$  é dada por:

$$ec(i) = \max_{j \in V_i} d(i, j).$$

Para garantir que os nós mais centrais estejam mais próximos dos outros, a centralidade de excentricidade do nó  $i$  é dada pelo recíproco da sua excentricidade:

$$C_{ec}(i) = \frac{1}{ec(i)}.$$

# Excentricidade

## Exemplo

Em um grafo completo todos os nós possuem excentricidade e centralidade de excentricidade iguais a 1. Em um círculo com  $2n$  vértices, todos os nós tem excentricidade igual a  $n$  e centralidade de excentricidade igual a  $1/n$ . Em uma linha com  $n$  vértices, a excentricidade das folhas é  $n-1$  e a centralidade de excentricidade é  $1/(n-1)$ .

# Métricas geométricas

## Proximidade

É igual ao recíproco da média aritmética das distâncias geodésicas do nó para os demais nós da mesma componente do nó, ou seja:

$$C_c(i) = \frac{||V_i|| - 1}{\sum_{j \in V_i - \{i\}} d(i, j)}.$$



# Centralidade de Proximidade

## Exemplo

Em um círculo com  $2n$  nós, a centralidade de proximidade de qualquer nó  $i$  é dada por:

$$\frac{2n-1}{n + \sum_{j=1}^{n-1} 2j} = \frac{2n-1}{n^2}.$$

Por outro lado, em um círculo com  $2n+1$  nós, a centralidade de proximidade de qualquer nó  $i$  é dada por:

$$\frac{2n}{\sum_{j=1}^n 2j} = \frac{2n}{n(n+1)} = \frac{2}{n+1}.$$

# Métricas geométricas

## Harmônica

Recíproco da média harmônica das distâncias:

$$C_h(i) = \frac{1}{n-1} \sum_{j \neq i} \frac{1}{d(i, j)},$$

em que  $n$  é o número total de nós na rede.

Bem definida em redes com mais de uma componente em que existem nós que não se conectam, e portanto, têm distâncias geodésicas infinitas.

# Centralidade Harmônica

## Exemplo

Vamos considerar uma rede que é formada por duas componentes sendo uma correspondente a um grafo estrela com  $n_1$  nós e outra correspondente a um círculo com  $n_2$  nós. Então, a centralidade harmônica de um nó periférico da estrela é:

$$\frac{1}{n_1 + n_2 - 1} \left( 1 + (n_1 - 2) \frac{1}{2} \right) = \frac{n_1}{2(n_1 + n_2 - 1)}.$$

A centralidade harmônica do nó central da estrela é:

$$\frac{1}{n_1 + n_2 - 1} (n_1 - 1).$$

Finalmente, a centralidade harmônica dos nós no círculo serão:

$$\begin{cases} \frac{1}{n_1 + n_2 - 1} \left( \frac{2}{n_2} + \sum_{k=1}^{\frac{n_2}{2}-1} \frac{2}{k} \right) & \text{se } n_2 \text{ for par;} \\ \frac{1}{n_1 + n_2 - 1} \left( \sum_{k=1}^{\frac{n_2-1}{2}} \frac{2}{k} \right) & \text{se } n_2 \text{ for ímpar.} \end{cases}$$

# Métricas geométricas

## Média- $p$




$$C_p(i) = \begin{cases} \left( \frac{\sum_{j \in V_i - \{i\}} d(i, j)^p}{n-1} \right)^{-\frac{1}{p}}, & \text{se } p \neq 0, \\ \left( \prod_{j \in V_i - \{i\}} d(i, j) \right)^{-\frac{1}{n-1}}, & \text{se } p = 0. \end{cases}$$

- $C_0(i) = \lim_{p \rightarrow 0} C_p(i)$ : média geométrica.
- $C_{-1}(i) = C_h(i)$ .
- $C_1(i) = C_c(i) \times \frac{n-1}{\|V_i\|-1}$ .
- $\lim_{p \rightarrow +\infty} C_p(i) = C_{ec}(i)$ .

# Métricas geométricas: Exemplo I



```
1 import matplotlib.pyplot as plt
2 import numpy as np
3 import networkx as nx
4
5 plt.close('all')
6 #grafo aleatório de Erdős-Rényi com 1000 nós e probabilidade 0.01
7 ger = nx.gnp_random_graph(1000,0.01)
8 graus = dict(nx.degree(ger)).values()
9
10 #centralidade de excentricidade
11 ec = nx.eccentricity(ger)
12 cec = [1.0/ec[n] for n in ec]
13
14 #centralidade de proximidade
15 #só salvamos os valores do dicionário e transformamos em lista
16 cc = list(nx.closeness centrality(ger).values())
17
18 #centralidade harmônica
19 #só salvamos os valores do dicionário e transformamos em lista
20 chu = list(nx.harmonic centrality(ger).values())
21 ch = [x/(len(chu)-1) for x in chu] #normalização
```

# Métricas geométricas: Exemplo II



Média- $p$ : Exemplo I

```
1 #valores de p
2 p = np.linspace(-1,201,1000)
3 #sp = comprimento dos caminhos mais curtos desde nó 1
4 sp= np.array(list(nx.shortest_path_length(ger,1).values()))
5 #cp = centralidade generalizada para o nó 1
6 cp= np.zeros_like(p)
7 for k in range(p.shape[0]):
8     if p[k]:
9         cp[k] = np.mean(sp[1:]**p[k])**(-1.0/p[k])
10    else:
11        cp[k] = np.prod(sp[1:]**(-1.0/(sp.shape[0]-1)))
```



# Centralidade de Intermediação

## Ideia

Quantifica o quanto os vértices são capazes de atuar como intermediários entre outros dois vértices, podendo portanto controlar o fluxo de informação entre eles.

## Definição

$$C_b(i) = \frac{1}{(n-1)(n-2)} \sum_{(j,k): j \neq k, i \notin \{j,k\}} \frac{Q_{j,k}(i)}{Q_{j,k}},$$

onde  $Q_{j,k}$  é o número de caminhos geodésicos iniciando no vértice  $j$  e terminando no vértice  $k$  e que  $Q_{j,k}(i)$  é o número de caminhos geodésicos que iniciam em  $j$ , terminam em  $k$  e passam pelo vértice  $i$ .



# Centralidade de Intermediação

## Exemplo


Considere novamente a rede que consiste de uma estrela de  $n_1$  nós e um círculo de  $n_2$  nós, mas na qual adicionamos uma ligação entre o nó central da estrela e um nó do círculo. Note que qualquer caminho geodésico partindo de (resp., terminando em) um nó periférico da estrela passa pelo vértice central da estrela. Deste modo, a centralidade de intermediação do nó central da estrela é:

$$\begin{aligned} & \frac{1}{(n_1 + n_2 - 1)(n_1 + n_2 - 2)} [(n_1 - 1)(n_1 + n_2 - 2) + n_2(n_1 - 1)] \\ = & \frac{(n_1 - 1)(n_1 + 2n_2 - 2)}{(n_1 + n_2 - 1)(n_1 + n_2 - 2)}. \end{aligned}$$

Além disso, os nós periféricos da estrela possuem centralidade de intermediação nula.

# Centralidade de Intermediação: Exemplo I

```
1 #centralidade de intermediação
2 #só salvamos os valores do dicionário e transformamos em lista
3 cb = list(nx.betweenness_centrality(ger, normalized=True).values())
4 plt.figure()
5 plt.plot(grau, cb, 'o')
6 plt.xlabel('grau')
7 plt.ylabel('centralidade')
```



# Centralidade de Autovetor

## Definição

$$C_{eg}(i) = \frac{1}{\lambda_1} \sum_{j=1}^n A(i, j) C_{eg}(j),$$

em que  $\lambda_1$  o maior autovalor de  $A$ .

Em redes direcionadas, temos duas opções para a centralidade de autovetor, a depender se um vértice recebe importância dos vértices que estão ligados a ele ou dos vértices aos quais ele está ligado. Em geral, temos a primeira situação. É comum normalizar o vetor de centralidades de autovetor de modo que este tenha normal euclidiana 1.

## Problemas

Em redes direcionadas, nós que possuem grau de entrada nulo possuem centralidade de autovetor nula.

Todos os nós em uma rede direcionada acíclica possuem centralidade de autovetor nula.

# Centralidade de Katz

## Ideia

A centralidade de Katz resolve o problema adicionando um valor pequeno de centralidade para todos os nós da rede:

$$C_K(i) = \alpha \sum_{j \neq i} A(i, j) C_K(j) + \beta,$$

em que  $\alpha$  e  $\beta$  são constantes positivas.  $\beta$  é o valor de centralidade que os nós de grau nulo possuem e  $\alpha < 1/\lambda_1$  em que  $\lambda_1$  é o maior autovalor de  $A$ . Na prática, é comum adotar-se o valor de  $\alpha$  próximo a esse valor máximo e com um pequeno valor de  $\beta$ .

# PageRank

## Ideia

De acordo com a centralidade de Katz, o fato de que algum vértice importante está ligado a um dado vértice dá alta importância a este dado vértice, independente de quantas ligações na rede possui aquele vértice importante.

O PageRank assume que a importância de um nó é dividida igualmente entre os seus vizinhos para os quais ele possui ligação. Deste modo:


$$C_{PR}(i) = (1 - \alpha) + \alpha \sum_{j \neq i} \frac{A(j, i) C_{PR}(j)}{d^{out}(j)},$$

em que  $\alpha \in (0, 1)$  (usualmente,  $\alpha = 0,85$ ). O PageRank é utilizado pelo Google.  $\alpha$  pode ser pensado como a probabilidade de um usuário continuar navegando entre páginas através dos links. No caso de um vértice  $j$  com  $d^{out}(j)$  nulo, como  $j$  não contribui para a importância de nenhum outro nó, adotaremos a convenção de que  $d^{out}(j) = 1$ , de modo que o termo  $A(j, i)/d^{out}(j)$  seja nulo.


# Autovetor & Katz: Exemplo I

```
1 import numpy as np
2 import networkx as nx
3
4 #grafo aleatório de Erdős-Rényi com 1000 nós e probabilidade
   0.01
5 ger = nx.gnp_random_graph(1000,0.01)
6 graus = dict(nx.degree(ger)).values()
7
8 #centralidade de autovetor
9 cev = list(nx.eigenvector_centrality_numpy(ger).values())
10 #centralidade de Katz
11 ck1 = list(nx.katz_centrality_numpy(ger,alpha=0.08,beta=1).
   values())
12 ck2 = list(nx.katz_centrality_numpy(ger,alpha=0.01,beta=1).
   values())
13 ck3 = list(nx.katz_centrality_numpy(ger,alpha=0.08,beta=2).
   values())
```

# Autovetor & Katz: Exemplo II




(a) Centralidade de autovetor.




(b) Katz com  $\alpha = 0.08$  e  $\beta = 1$ .

## Autovetor &amp; Katz: Exemplo III



(a) Centralidade de Katz com  $\alpha = 0.01$  e  $\beta = 1$ .




(b) Centralidade de Katz com  $\alpha = 0.08$  e  $\beta = 2$ .




# PageRank: Exemplo I

```
1 import networkx as nx
2
3 #grafo aleatório de Erdős-Rényi com 1000 nós e probabilidade
  0.01
4 ger = nx.gnp_random_graph(1000,0.01)
5 graus = dict(nx.degree(ger)).values()
6
7 #centralidade de PageRank
8 cpr1 = list(nx.pagerank(ger,alpha=0.85).values())
9 cpr2 = list(nx.pagerank(ger,alpha=0.65).values())
10 cpr3 = list(nx.pagerank(ger,alpha=0.25).values())
```


# PageRank: Exemplo II



(a)  $\alpha = 0.85$ .



(b)  $\alpha = 0.65$ .



(c)  $\alpha = 0.25$ .

# Coefficiente de Agrupamento Local

## Definição

Permite avaliar o quanto os nós são capazes de proporcionar interação entre os seus vizinhos. O coeficiente de agrupamento local de um nó  $i$  é dado por:

$$cl(i) = \frac{\sum_{(j,k): j \neq i, k \neq i, k \neq j} A(i, j) A(i, k) A(j, k)}{\sum_{(j,k): j \neq i, k \neq i, k \neq j} A(i, j) A(i, k)}.$$

Pode-se definir o coeficiente de agrupamento local médio:

$$\overline{cl}(G) = \frac{1}{n} \sum_{i=1}^n cl(i).$$

## Coeficiente de Agrupamento Local: Exemplo I

Considere uma rede que consiste de um círculo com  $n - 1$  nós todos conectados a um nó central. Pode-se mostrar que:

$$\overline{cl}(G) = \frac{1}{n} \left[ \frac{2(n-1)}{3} + \frac{2}{n-2} \right] = \frac{2n^2 - 6n + 10}{3n(n-2)}.$$

e

$$cl(G) = \begin{cases} 1 & \text{se } n = 4, \\ \frac{2(n-1)+(n-1)}{3(n-1)+\frac{(n-1)(n-2)}{2}} = \frac{6}{n+4} & \text{se } n > 4. \end{cases}$$

## Coeficiente de Agrupamento Local: Exemplo II


Em uma rede em que todos os vértices têm grau no mínimo igual a 2, pode-se mostrar que:

$$cl(G) = \sum_{i=1}^n cl(i) \frac{d(i)(d(i)-1)/2}{\sum_{j=1}^n d(j)(d(j)-1)/2},$$


em que  $cl(G)$  é o coeficiente de agrupamento total e  $cl(i)$  é o coeficiente de agrupamento local do vértice  $i$ .

```
1 import networkx as nx
2 import numpy as np
3
4 ccla = []
5 cclt = []
6 n = np.linspace(5, 500, 496)
7 for k in n:
8     gci = nx.wheel_graph(int(k))
9     ccla.append(nx.average_clustering(gci))
10    cclt.append(nx.transitivity(gci))
```

# Coeficiente de Agrupamento Local: Exemplo III



(a) Agrupamento médio.



(b) Agrupamento total.

# Homofilia

## Ideia

Uma das informações importantes em redes complexas e, em especial, em redes sociais é saber se os nós possuem alguma tendência se ligar mais a nós similares a si mesmo, o que é conhecido como homofilia ou associatividade. Por exemplo, cientistas tendem a ter contato com mais cientistas que, em geral, outras pessoas possuem contatos com cientistas. Pessoas tendem a ter mais relacionamentos intrarraciais que inter-raciais.

# Índice EI

## Definição

Considere um grafo particionado em grupos  $\{V^1, V^2, \dots, V^a\}$  de acordo com atributos que esses nós possuam. O índice EI mede a homofilia através de uma razão que envolve a quantidade de ligações entre nós de grupos distintos ( $EL$ ) e a quantidade de ligações entre nós do mesmo grupo ( $IL$ ). Ele pode ser calculado para um subconjunto qualquer de nós da rede  $V'$ :

$$EI(V') = \frac{EL(V') - IL(V')}{EL(V') + IL(V')}.$$

O valor do índice EI varia no intervalo  $[-1, 1]$ , em que um índice EI igual a -1 (resp., 1) indica um subconjunto de nós que só possui ligações internas (resp., externas).



# Índice EI

## Problema

- O valor do índice EI é afetado pelo fato de um certo grupo de atributos ser mais ou menos frequente na rede que outros.
  - Suponha que um indivíduo faça parte de algum grupo minoritário.
  - Pode acontecer que este indivíduo possua mais ligações externas do que internas no grupo e, portanto, tenha um índice EI positivo.
  - Isso não necessariamente quer dizer que este indivíduo tenha preferência por ter ligações externas.
- Precisaríamos comparar com o número esperado de ligações que seria obtido em uma rede aleatória com o mesmo conjunto de nós e o mesmo número de arestas escolhidas aleatoriamente.

# Assortatividade

## Definição

A fração de arestas que ligam um nó no conjunto  $V^i$  a um nó no conjunto  $V^j$ :

$$e_{ij} = \frac{1}{c} \sum_{k_1 \in V^i} \sum_{k_2 \in V^j} A(k_1, k_2),$$

em que  $c = m$  ou  $c = 2m$  se a rede é direcionada ou não-direcionada, respectivamente.

A fração de arestas que iniciam (resp., terminam) em vértices do conjunto  $V_i$  é dada, respetivamente, por  $a_i = \sum_j e_{ij}$ ,  $b_i = \sum_j e_{ji}$ . O coeficiente de assortatividade é dado por:

$$As^c(G) = \frac{\sum_{i=1}^a e_{ii} - \sum_{i=1}^a a_i b_i}{1 - \sum_{i=1}^a a_i b_i},$$

em que a normalização no denominador é para garantir que, no caso de homofilia perfeita, o coeficiente tenha valor igual a 1.

# Homofilia


## Exemplo

Considere a rede da Figura abaixo. Para calcular o valor do índice EI da rede, temos:  $EI = \frac{2-8}{2+8} = -0.6$ .

Já o valor da assortatividade categórica é dado por:

$$As^c(G) = \frac{6/20 + 10/20 - (8/20)^2 - (12/20)^2}{1 - (8/20)^2 - (12/20)^2} = 0.583.$$

Ambas as métricas indicam uma rede com homofilia.



# Assortatividade

## Definição para atributos escalares

O coeficiente de assortatividade para atributos escalares é calculado como o coeficiente de correlação de Pearson. Seja  $x_i$  o atributo escalar do nó  $i$ . Como o nó  $i$  possui  $d(i)$  arestas ligadas a ele, o valor médio dos atributos escalares ao longo das arestas é dado por:

$$\bar{x} = \frac{\sum_i d(i)x_i}{\sum_i d(i)} = \frac{1}{2m} \sum_i d(i)x_i.$$

O coeficiente de assortatividade é:

$$As^e(G) = \frac{\frac{1}{2m} \sum_{ij} (A(i, j)x_i x_j) - \bar{x}^2}{\frac{1}{2m} \sum_{ij} (A(i, j)x_i^2) - \bar{x}^2}.$$

# Assortatividade de grau

## Caso especial


- Um caso especial de assortatividade com atributo escalar que é bastante utilizado é quando o atributo escalar é a própria centralidade de grau, ou seja,  $x_i = d(i)$ .
- Esta assortatividade mede se na rede existe uma tendência de nós muito conectados estarem conectados entre si e nós pouco conectados estarem ligados entre si.
- Redes com assortatividade de grau positiva possuem nós bastante conectados ligados entre si, formando um núcleo da rede que se destaca da periferia. Essa tendência é bastante observada em redes sociais.

# Assortatividade: Exemplo I

```
1 import pandas as pd
2 import networkx as nx
3 import matplotlib.pyplot as plt
4
5 def carregarlivro(livro):
6     atri = pd.read_csv('hpattributes.txt', sep='\t') #sem encabeçamento
7     ares = pd.read_csv('hpbook{:1d}.txt'.format(livro), sep=' ', header=None)
8     nome = pd.read_csv('hpnames.txt', sep='\t')
9
10    gpotter = nx.DiGraph()
11    n = atri.shape[0]
12    #Primeiro agregamos os nós
13    for k in range(n):
14        gpotter.add_node(k, nome=nome['name'][k],
15                        ano=atri['schoolyear'][k],
16                        gen=atri['gender'][k],
17                        casa=atri['house'][k])
18    #Construímos a rede
19    for k in range(n):
20        for m in range(n):
21            if ares.values[k][m] == 1:
22                gpotter.add_edge(k,m)
23
24    agen = nx.attribute_assortativity_coefficient(gpotter, "gen")
25    acasa = nx.attribute_assortativity_coefficient(gpotter, "casa")
26    aano = nx.numeric_assortativity_coefficient(gpotter.to_undirected(), "ano")
27    agrau = nx.degree_assortativity_coefficient(gpotter.to_undirected())
28
29    return agen, acasa, aano, agrau
```

# Assortatividade: Exemplo II

```
30  
31 agen = 6*[0]  
32 acasa= 6*[0]  
33 aano = 6*[0]  
34 agrau= 6*[0]  
35 livros = [1,2,3,4,5,6]  
36 for k in range(len(livros)):  
37     agen[k], acasa[k], aano[k], agrau[k]= carregarlivro(livros[k])
```



# Obrigado!

## Contatos:

Leandro Rêgo - leandro@dema.ufc.br

Jesus Ossian - jesus.ossian@dema.ufc.br

Pablo Fierens - pfierens@itba.edu.ar